

CONDICIONES DE OPTIMALIDAD

ALAN REYES-FIGUEROA
MÉTODOS NUMÉRICOS II

(AULA 15) 23.AGOSTO.2021

Definición

Suponga que $f : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ es una función con valores reales, definida sobre Ω . Un punto $\mathbf{x}^* \in \Omega$ es un **mínimo local** o **minimizador local** de f si existe $\varepsilon > 0$ tal que

$$f(\mathbf{x}) \geq f(\mathbf{x}^*), \quad \text{para todo } \mathbf{x} \in \Omega - \{\mathbf{x}^*\} \text{ con } \|\mathbf{x} - \mathbf{x}^*\| < \varepsilon.$$

Definición

Suponga que $f : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ es una función con valores reales, definida sobre Ω . Un punto $\mathbf{x}^* \in \Omega$ es un **mínimo global** o **minimizador global** de f sobre Ω si

$$f(\mathbf{x}) \geq f(\mathbf{x}^*), \quad \text{para todo } \mathbf{x} \in \Omega, \mathbf{x} \neq \mathbf{x}^*.$$




Obs! Reemplazando \geq con $>$ en las definiciones anteriores obtenemos el concepto de un **mínimo local estricto** y de un **mínimo global estricto**, respectivamente.

Optimización

Ejemplo: La función $f : \mathbb{R} \rightarrow \mathbb{R}, f(x) = x^2$ tiene un mínimo global estricto en $x = 0$. Claramente, $x = 0$ también es un mínimo local de f .

Ejemplo: La función $f : \mathbb{R} \rightarrow \mathbb{R}$, dada por $f(x) = \max\{0, |x - 2|\}$ tiene a todos los puntos de intervalo $[-2, 2]$ como mínimos globales. Estos no son estrictos.

Ejemplo: La función $f : \mathbb{R} \rightarrow \mathbb{R}, f(x) = 3x^4 - 8x^3 - 6x^2 + 12x$ tiene mínimos locales estricto en $x = -1$ y $x = 2$. De éstos, sólo $x = -1$ es un mínimo global.




Definición

Un punto $\mathbf{x}^* \in \Omega$ es un **mínimo local aislado** de $f : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, si \mathbf{x}^* es mínimo local de f y existe una vecindad $U \subset \mathbb{R}^n$ de \mathbf{x}^* tal que \mathbf{x}^* es el único mínimo local de f en U .


Un punto $\mathbf{x}^* \in \Omega$ es un **mínimo local no aislado** de f , si para toda vecindad U de \mathbf{x}^* , existe $\mathbf{x} \in U$, $\mathbf{x} \neq \mathbf{x}^*$, tal que \mathbf{x} también es mínimo local de f .

Ejemplo: La función $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = x^2 \cos \frac{1}{x} + x^2$, $f(0) = 0$, posee un mínimo local no estricto y no aislado en $x = 0$.

Ejemplo: La función $g : \mathbb{R} \rightarrow \mathbb{R}$, $g(x) = x^2 \cos \frac{1}{x} + 2x^2$, $g(0) = 0$, posee un mínimo local estricto y no aislado en $x = 0$.



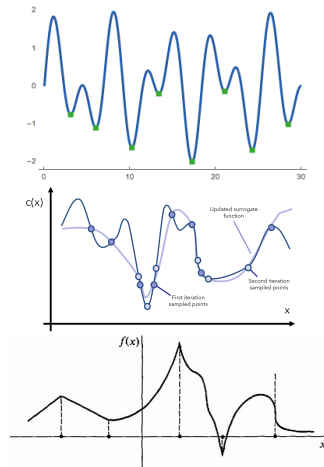
Optimización



Optimización

Dificultades de la optimización global:

- funciones con muchos mínimos;
- los algoritmos tienden a quedarse atrapados en mínimos locales,
- en el caso de métodos de búsqueda, puede que el óptimo global esté en una región no explorada;
- cuando el mínimo se encuentra dentro de una región donde la función es muy plana (curvatura cercana a 0), los métodos de optimización suelen ser muy lentos;
- no-diferenciabilidad en un punto mínimo.



Optimización

Fórmula de Taylor:

Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es de clase C^{m+1} sobre \mathbb{R}^n , y $\mathbf{h} = \mathbf{x} - \mathbf{x}_0$, entonces

$$f(\mathbf{x}) = f(\mathbf{x}_0) + \sum_{k=0}^m \frac{1}{k!} D^{(k)}f(\mathbf{x}_0) \cdot \mathbf{h}^{(k)} + \frac{1}{(m+1)!} D^{(m+1)}f(\mathbf{x}_0 + t\mathbf{h}) \cdot \mathbf{h}^{(m+1)},$$

donde $t \in (0, 1)$ y

$$D^{(k)}f(\mathbf{x}_0) \cdot \mathbf{h}^k = \sum_{|l|=k} \frac{\partial^k f}{\partial \mathbf{x}_l}(\mathbf{x}_0) \mathbf{h}_l = \sum_{|l|=k} \frac{\partial^k f}{\partial x_1^{i_1} \cdots \partial x_n^{i_n}} h_1^{i_1} h_2^{i_2} \cdots h_n^{i_n},$$

$l = (i_1, \dots, i_n)$, $\mathbf{x}_l = (x_{i_1}, \dots, x_{i_n})$, $\mathbf{h}_l = (h_{i_1}, \dots, h_{i_n})$.

Casos particulares:

Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es de clase C^2 , podemos escribir

$$f(\mathbf{x}) = f(\mathbf{x}_0) + Df(\mathbf{x}_0 + t\mathbf{h}), \quad t \in (0, 1).$$

$$f(\mathbf{x}) = f(\mathbf{x}_0) + Df(\mathbf{x}_0) \cdot \mathbf{h} + \frac{1}{2} \mathbf{h}^T D^2f(\mathbf{x}_0 + t\mathbf{h}) \mathbf{h}, \quad t \in (0, 1).$$

Condiciones de Optimalidad

Teorema (Condiciones de Optimalidad de Primer Orden)

Si \mathbf{x}^* es un mínimo local (o un máximo local) de la función $f : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, y f es de clase C^1 en una vecindad abierta de \mathbf{x}^* , entonces $\nabla f(\mathbf{x}^*) = \mathbf{0}$.

Prueba: Hacemos la prueba para \mathbf{x}^* mínimo local. Suponga que $\nabla f(\mathbf{x}^*) \neq \mathbf{0}$. Por lo tanto, podemos encontrar una dirección $\mathbf{h} = -\alpha \frac{\nabla f(\mathbf{x}^*)}{\|\nabla f(\mathbf{x}^*)\|} = -\alpha \mathbf{u}$, tal que $D_{\mathbf{u}}f(\mathbf{x}^*) = \nabla f(\mathbf{x}^*)^T \mathbf{u} < 0$.

Por el Teorema de Taylor, si $\mathbf{x} = \mathbf{x}^* + \mathbf{h}$, tenemos $f(\mathbf{x}) = f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T \mathbf{h} + o(\|\mathbf{h}\|)$. Cuando $\alpha \rightarrow 0$, entonces $\mathbf{h} \rightarrow \mathbf{0}$, resulta que $\nabla f(\mathbf{x}^*)^T \mathbf{h} + o(\|\mathbf{h}\|) < 0$, ya que $o(\|\mathbf{h}\|)$ se acerca a cero, mucho más rápido que $\nabla f(\mathbf{x}^*)^T \mathbf{h}$. De hecho,

$$\lim_{\alpha \rightarrow 0} \frac{|\nabla f(\mathbf{x}^*)^T \mathbf{h}|}{\|\mathbf{h}\|} = \frac{\nabla f(\mathbf{x}^*)^T \mathbf{u}}{\|\mathbf{u}\|} = \nabla f(\mathbf{x}^*)^T \mathbf{u} < 0.$$

De ahí que, $f(\mathbf{x}) < f(\mathbf{x}^*)$, y esto contradice el la hipótesis de que \mathbf{x}^* es un mínimo local. Portanto, $\nabla f(\mathbf{x}^*) = \mathbf{0}$. \square

Condiciones de Optimalidad

Definición

Un punto $\mathbf{x} \in \Omega = \text{dom } f$ que satisface que $\nabla f(\mathbf{x}) = \mathbf{0}$ se llama un **punto crítico** o **punto estacionario** de f .

De acuerdo a la condición de Optimalidad de Primer Orden, todo mínimo local debe ser un punto estacionario de f .

Teorema (Condiciones de Optimalidad de Segundo Orden)

Si $\mathbf{x}^* \in \mathbb{R}^n$ es un mínimo (máximo) local de $f : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, y f es de clase C^2 es una vecindad abierta de \mathbf{x}^* , entonces $\nabla f(\mathbf{x}^*) = \mathbf{0}$, y la hessiana

$$D^2f(\mathbf{x}^*) \succeq \mathbf{0}$$

es positiva semidefinida (negativa semidefinida).

Prueba: Al igual que antes, hacemos la prueba para el caso de \mathbf{x}^* mínimo local. El caso del máximo se prueba de forma similar.

Condiciones de Optimalidad

Suponga que $D^2f(\mathbf{x}^*)$ no es positiva semidefinida. Entonces, existe $\mathbf{h} \in \mathbb{R}^n$ tal que $\mathbf{h}^T D^2f(\mathbf{x}^*) \mathbf{h} < 0$.

Por continuidad de D^2f , y la preservación de signo, existe una bola $\mathbb{D}_r(\mathbf{x}^*)$ y un intervalo $(0, \varepsilon)$, tal que $\mathbf{h}^T D^2f(\mathbf{x}^* + \hat{\varepsilon}\mathbf{h}) \mathbf{h} < 0$, para todo $\hat{\varepsilon} \in (0, \varepsilon)$.

Aplicando el Teorema de Taylor alrededor de \mathbf{x}^* , existe $t \in (0, 1)$, tal que

$$f(\mathbf{x} + \hat{\varepsilon}\mathbf{h}) = f(\mathbf{x}^*) + \hat{\varepsilon}\nabla f(\mathbf{x}^*)^T \mathbf{h} + \frac{1}{2}\hat{\varepsilon}^2 \mathbf{h}^T D^2f(\mathbf{x}^* + t\hat{\varepsilon}\mathbf{h}) \mathbf{h}.$$

Usando el hecho que $\nabla f(\mathbf{x}^*)^T \mathbf{h} = 0$ (ya que \mathbf{x}^* es mínimo local), y el hecho que $\mathbf{h}^T D^2f(\mathbf{x}^* + t\hat{\varepsilon}\mathbf{h}) \mathbf{h} < 0$, obtenemos

$$f(\mathbf{x}^* + \hat{\varepsilon}\mathbf{h}) < f(\mathbf{x}^*),$$

lo cual contradice la hipótesis de que \mathbf{x}^* es un mínimo local de f . Portanto, $D^2f(\mathbf{x}^*)$ es positiva semidefinida. \square

Condiciones de Optimalidad

Teorema (Condiciones Suficientes de Optimalidad)

Suponga que D^2f existe y es continua en una vecindad de $\mathbf{x}^* \in \mathbb{R}^n$, que $\nabla f(\mathbf{x}^*) = \mathbf{0}$, y que la hessiana $D^2f(\mathbf{x}^*)$ es positiva definida (negativa definida).

Entonces \mathbf{x}^* es un mínimo (máximo) local estricto de f .

Prueba: Existe una bola $\mathbb{D}_r(\mathbf{x}^*) = \{\mathbf{x} : \|\mathbf{x} - \mathbf{x}^*\| < r\}$ para la cual

$q(t) = \mathbf{h}^T D^2f(\mathbf{x}^* + t\mathbf{h}) \mathbf{h} > 0$, para todo $\mathbf{x}^* + t\mathbf{h} \in \mathbb{D}_r$, con $t \in (0, 1)$ y $\mathbf{h} = \mathbf{x} - \mathbf{x}^*$.

(Esto es consecuencia de la preservación de signo, ya que la función q es continua y $q(0) = \mathbf{h}^T D^2f(\mathbf{x}^*) \mathbf{h} > 0$).

Usando el Teorema de Taylor, con $\|\mathbf{h}\| < r$, y como $\nabla f(\mathbf{x}^*) = \mathbf{0}$, se tiene que existe $t \in (0, 1)$ tal que

$$f(\mathbf{x}) = f(\mathbf{x}^*) + \frac{1}{2} \mathbf{h}^T D^2f(\mathbf{x}^* + t\mathbf{h}) \mathbf{h},$$

Como $\mathbf{x}^* + t\mathbf{h} \in \mathbb{D}_r(\mathbf{x}^*)$, luego $\mathbf{h}^T D^2f(\mathbf{x}^* + t\mathbf{h}) \mathbf{h} > 0 \Rightarrow f(\mathbf{x}) > f(\mathbf{x}^*)$, para todo $\mathbf{x} \in \mathbb{D}_r(\mathbf{x}^*)$. Esto muestra que \mathbf{x}^* es un mínimo local estricto de f . \square

Condiciones de Optimalidad

Podemos encontrar y clasificar puntos estacionarios de la siguiente manera:

1. Encontrar los puntos críticos \mathbf{x} en los que $f(\mathbf{x}) = 0$.
2. Obtener la Hessiana $Hf(\mathbf{x}) = D^2f(\mathbf{x})$.
3. Determinar el carácter de $Hf(\mathbf{x})$ para cada punto crítico \mathbf{x} .
 - Si $D^2f(\mathbf{x})$ es positiva (negativa) definida, entonces \mathbf{x} es un mínimo (máximo) local.
 - Si $D^2f(\mathbf{x})$ es indefinida, \mathbf{x} es un punto silla.
 - Si $D^2f(\mathbf{x})$ es positiva (negativa) semidefinida, \mathbf{x} puede ser un mínimo (máximo) local. En este caso, es necesario seguir trabajando para clasificar el punto estacionario.

Un posible enfoque sería para deducir las terceras derivadas parciales de $f(\mathbf{x})$ y luego calcular el término correspondiente en la serie de Taylor. Si este término es cero, entonces el siguiente término necesita ser calculado y así por delante.

Condiciones de Optimalidad

- En el caso especial donde $D^2f(\mathbf{x}) = 0$, \mathbf{x} puede ser un minimizador o maximizador ya que las condiciones necesarias se satisfacen tanto en casos.
- Si $D^2f(\mathbf{x})$ es semidefinida, se requiere más información para caracterización completa de un punto estacionario y más el trabajo es necesario en este caso.
- Un posible enfoque podría ser calcular el tercer término de la serie de Taylor de $f(\mathbf{x})$,

$$D^3f(\mathbf{x}) \cdot \mathbf{h}^{(3)} = \frac{1}{3!} \sum_{|I|=3} \frac{\partial^3 f}{\partial \mathbf{x}_I}(\mathbf{x}_0) \mathbf{h}_I = \frac{1}{3!} \sum_{i=1}^3 \sum_{j=1}^3 \sum_{k=1}^3 \frac{\partial^3 f}{\partial x_1^{i_1} \partial x_2^{i_2} \partial x_3^{i_3}} h_1^{i_1} h_2^{i_2} h_3^{i_3};$$

y se debe determinar el signo de este término. Si este término es cero, entonces debe calcularse el siguiente término $D^4f(\mathbf{x})$.

- En general, si los primeros i términos $D^i f(\mathbf{x})$ de la serie de Taylor son todos nulos, debe calcularse el signo de primer término $D^k f(\mathbf{x}) \cdot \mathbf{h}^{(k)}$ que no se anule.

Condiciones de Optimalidad

Ejemplo: Considere la función $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, dada por $f(\mathbf{x}) = \frac{1}{6}[(x_1 - 2)^3 + (x_2 - 3)^3]$. En este caso, el gradiente es

$$\nabla f(\mathbf{x}) = \frac{1}{2} \begin{pmatrix} (x_1 - 2)^2 & (x_2 - 3)^2 \end{pmatrix}.$$

Resolviendo $\nabla f(\mathbf{x}) = \mathbf{0}$, se obtiene que el único punto crítico es $\mathbf{x}^* = (2, 3)^T$. La Hessiana de f es

$$D^2f(\mathbf{x}) = \begin{pmatrix} x_1 - 2 & 0 \\ 0 & x_2 - 3 \end{pmatrix}.$$

Así, en el punto crítico, $D^2(\mathbf{x}^*) = \mathbf{0}$. Las terceras derivadas de f son todas cero, excepto

$$\frac{\partial^3 f}{\partial x_1^3}(\mathbf{x}) = \frac{\partial^3 f}{\partial x_2^3}(\mathbf{x}) = 1.$$

Luego, el término


$$D^3f(\mathbf{x}^*) \cdot \mathbf{h}^{(3)} = \frac{1}{3!} \sum_{i=1}^3 \sum_{j=1}^3 \sum_{k=1}^3 \frac{\partial^3 f}{\partial x_1^{i_1} \partial x_2^{i_2} \partial x_3^{i_3}} h_1^{i_1} h_2^{i_2} h_3^{i_3} = \frac{1}{6}(h_1^3 + h_2^3)$$

es positivo si $h_1, h_2 > 0$, pero es negativo si $h_1, h_2 < 0$. Portanto, $D^3f(\mathbf{x}^*) \cdot \mathbf{h}^{(3)}$ toma ambos signos, y \mathbf{x}^* es un punto silla de f .

Funciones Convexas

Definición

Un subconjunto $\Omega \subseteq \mathbb{R}^n$ es **convexo** si para todo $\mathbf{x}, \mathbf{y} \in \Omega$, el segmento de recta $[\mathbf{x}, \mathbf{y}] = \{(1-t)\mathbf{x} + t\mathbf{y} : t \in [0, 1]\}$ está totalmente contenido en Ω .



(a) Conjunto no convexo, (b) Conjunto convexo.

Ejemplos:

- Convexos: esferas, hiperplanos, semiespacios, conos, ...
- No Convexos: conjunto no conexos, uniones de rectas, uniones en general, ...

Funciones Convexas

Definición


Una función $f : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ es **convexa** si $\Omega = \text{dom } f$ es un conjunto convexo, y para todo $\mathbf{x}, \mathbf{y} \in \Omega$, y todo $t \in [0, 1]$ vale

$$f((1-t)\mathbf{x} + t\mathbf{y}) \leq (1-t)f(\mathbf{x}) + tf(\mathbf{y}). \quad (1)$$

Geométricamente, la desigualdad (1) significa que el segmento de recta entre $(\mathbf{x}, f(\mathbf{x}))$ y $(\mathbf{y}, f(\mathbf{y}))$ está por encima de la gráfica de f .

La función f es **estrictamente convexa** si en (1) vale la desigualdad estricta, siempre que $\mathbf{x} \neq \mathbf{y}$ y $t \neq 0, 1$. Decimos que f es **cóncava** (**estrictamente cóncava**) si $-f$ es convexa (estrictamente convexa).

A la desigualdad (1) se le llama usualmente **desigualdad de Jensen**.



Funciones Convexas

Propiedad

Sea $\Omega \subseteq \mathbb{R}^n$ conjunto convexo. La función $f : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ es convexa \iff para todo $\mathbf{x}_1, \dots, \mathbf{x}_k \in \Omega$, y cualesquiera $t_1, \dots, t_k \in [0, 1]$, con $\sum_{i=1}^k t_i = 1$, se tiene que

$$f\left(\sum_{i=1}^k t_i \mathbf{x}_i\right) \leq \sum_{i=1}^k t_i f(\mathbf{x}_i). \quad (2)$$

Prueba: (\Leftarrow) Para $k = 2$, tome $\mathbf{x}_1 = \mathbf{x}$, $\mathbf{x}_2 = \mathbf{y} \in \Omega$, y sean $t_1 = 1 - t$, $t_2 = t$, con $t \in [0, 1]$. La desigualdad (2) se reduce a $f((1 - t)\mathbf{x} + t\mathbf{y}) \leq (1 - t)f(\mathbf{x}) + tf(\mathbf{y})$, lo que implica que f es convexa.

(\Rightarrow) Mostramos la desigualdad (2) por inducción sobre k .

Para $k = 1$, necesariamente $t_1 = 1$ de modo que $f(\mathbf{x}_1) \leq f(\mathbf{x}_1)$ y (2) se cumple de manera automática. El caso $k = 2$ se cumple a partir de la definición de convexidad (1).

Suponga que (2) se cumple para cualesquiera k puntos $\mathbf{p}_1, \dots, \mathbf{p}_k \in \Omega$, siempre que se forme una combinación lineal convexa $s_1\mathbf{p}_1 + \dots + s_k\mathbf{p}_k$, con $0 \leq s_i \leq 1$ y $\sum_{i=1}^k s_i = 1$.

Funciones Convexas

Suponga ahora que $\mathbf{x}_1, \dots, \mathbf{x}_k, \mathbf{x}_{k+1} \in \Omega$, se combinan para formar un punto

$$\mathbf{x} = t_1 \mathbf{x}_1 + t_2 \mathbf{x}_2 + \dots + t_{k+1} \mathbf{x}_{k+1} \in \Omega, \quad \sum_{i=1}^{k+1} t_i = 1, \quad 0 \leq t_i \leq 1.$$

Definamos $t = t_{k+1}$, $1 - t = \sum_{j=1}^k t_j = t_1 + \dots + t_k$. Ambos coeficientes satisfacen $0 \leq t, 1 - t \leq 1$. En particular, si $\mathbf{p} = \sum_{j=1}^k s_j \mathbf{x}_j \in \Omega$, con $\sum_{j=1}^k s_j = 1$, podemos escribir

$$\mathbf{x} = (1 - t)\mathbf{p} + t\mathbf{x}_{k+1} = (1 - t) \sum_{j=1}^k s_j \mathbf{x}_j + t\mathbf{x}_{k+1} \implies t_j = (1 - t)s_j, \quad j = 1, \dots, k;$$

y



$$\begin{aligned} f\left(\sum_{i=1}^{k+1} t_i \mathbf{x}_i\right) &= f((1 - t)\mathbf{p} + t\mathbf{x}_{k+1}) \leq (1 - t)f(\mathbf{p}) + tf(\mathbf{x}_{k+1}) \\ &\leq (1 - t)f\left(\sum_{j=1}^k s_j \mathbf{x}_j\right) + tf(\mathbf{x}_{k+1}) \leq (1 - t) \sum_{j=1}^k s_j f(\mathbf{x}_j) + tf(\mathbf{x}_{k+1}) \\ &\leq \sum_{j=1}^k t_j f(\mathbf{x}_j) + tf(\mathbf{x}_{k+1}) \leq \sum_{i=1}^{k+1} t_i f(\mathbf{x}_i). \quad \square \end{aligned}$$

Funciones Convexas

Definición

Sea $f : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$. Definimos el **epígrafo** de f , como el conjunto

$$\text{Epi}(f) = \{(\mathbf{x}, y) \in \mathbb{R}^{n+1} : y \geq f(\mathbf{x})\} \subseteq \mathbb{R}^{n+1}.$$



Teorema

f es convexa \iff su epígrafo $\text{Epi}(f)$ es un conjunto convexo.