

Orden del Tema

1 Métodos de Región de Confianza

Recordatorio: Algoritmo Región de confianza

Recordatorio: Punto de Cauchy

Método Dogleg

El **Punto de Cauchy** es el minimizador del modelo $m_k(\mathbf{p})$ a lo largo de la dirección del máximo descenso, i.e., $\mathbf{p}_k = -\lambda_k \mathbf{g}_k$ sujeto a la región de confianza.

$$h(\lambda) := m_k(-\lambda \mathbf{g}_k) = f_k - \mathbf{g}_k^T \mathbf{g}_k \lambda + \frac{1}{2} \lambda^2 \mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k; \lambda \geq 0$$

Como $\|\mathbf{p}\| \leq \Delta_k$ entonces

$$\|-\lambda \mathbf{g}_k\| \leq \Delta_k \Rightarrow \lambda \leq \frac{\Delta_k}{\|\mathbf{g}_k\|} =: \bar{\lambda}$$

$$\lambda_k = \arg \min_{\lambda \in [0, \bar{\lambda}]} h(\lambda)$$

Cálculo del Punto de Cauchy

La solución del problema anterior es

$$\begin{aligned}
 \lambda_k &= \begin{cases} \bar{\lambda}, & \text{si } \mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k \leq 0 \\ \min \left(\bar{\lambda}, \frac{\|\mathbf{g}_k\|^2}{\mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k} \right), & \text{e.o.c.} \end{cases} \\
 &= \bar{\lambda} \begin{cases} 1, & \text{si } \mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k \leq 0 \\ \min \left(1, \frac{\|\mathbf{g}_k\|^3}{\Delta_k \mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k} \right), & \text{e.o.c.} \end{cases} \\
 &= \bar{\lambda} \tau_k
 \end{aligned}$$

Resumiendo: $\mathbf{p}_k^C = -\lambda_k \mathbf{g}_k$. Luego $\mathbf{p}_k^C = -\bar{\lambda} \tau_k \mathbf{g}_k = -\tau_k \frac{\Delta_k}{\|\mathbf{g}_k\|} \mathbf{g}_k$

Orden del Tema

1 Métodos de Región de Confianza

Recordatorio: Algoritmo Región de confianza

Recordatorio: Punto de Cauchy

Método Dogleg

Mejorando el Punto de Cauchy

- El **Paso de Cauchy** p_k^C produce un suficiente descenso en el modelo $m_k(\cdot)$ lo que permite obtener convergencia global.
- El costo computacional es bajo.
- Por las razones anteriores y teniendo en cuenta que usar el **Paso de Cauchy** p_k^C , es equivalente a usar el **Método del Máximo descenso** con un tamaño de paso particular, **será posible mejorar la solución al problema cuadrático con restricciones original?**

Mejorando el Punto de Cauchy

- El **Paso de Cauchy** p_k^C produce un suficiente descenso en el modelo $m_k(\cdot)$ lo que permite obtener convergencia global.
- El costo computacional es bajo.
- Por las razones anteriores y teniendo en cuenta que usar el **Paso de Cauchy** p_k^C , es equivalente a usar el **Método del Máximo descenso** con un tamaño de paso particular, **será posible mejorar la solución al problema cuadrático con restricciones original?**

Mejorando el Punto de Cauchy

- El **Paso de Cauchy** p_k^C produce un suficiente descenso en el modelo $m_k(\cdot)$ lo que permite obtener convergencia global.
- El costo computacional es bajo.
- Por las razones anteriores y teniendo en cuenta que usar el **Paso de Cauchy** p_k^C , es equivalente a usar el **Método del Máximo descenso** con un tamaño de paso particular, **será posible mejorar la solución al problema cuadrático con restricciones original?**

Mejorando el Punto de Cauchy

Observaciones

- El **Paso de Cauchy** p_k^C no depende fuertemente de la matriz B_k .
- Una mejor convergencia podría encontrarse si se usa la matriz B_k .
- Varios algoritmos de **Región de Confianza** primero calculan p_k^C y luego tratan de mejorar la solución.

Mejorando el Punto de Cauchy

Observaciones

- El **Paso de Cauchy** p_k^C no depende fuertemente de la matriz B_k .
- Una mejor convergencia podría encontrarse si se usa la matriz B_k .
- Varios algoritmos de **Región de Confianza** primero calculan p_k^C y luego tratan de mejorar la solución.

Mejorando el Punto de Cauchy

Observaciones

- El **Paso de Cauchy** p_k^C no depende fuertemente de la matriz B_k .
- Una mejor convergencia podría encontrarse si se usa la matriz B_k .
- Varios algoritmos de **Región de Confianza** primero calculan p_k^C y luego tratan de mejorar la solución.

Mejorando el Punto de Cauchy

Observaciones

- Una estrategia simple es calcular el paso completo $\mathbf{p}_k^B = -\mathbf{B}_k^{-1} \nabla f_k$ siempre que \mathbf{B}_k sea definida positiva
 - Si se cumple la restricción $\|\mathbf{p}_k^B\| \leq \Delta_k$, entonces el tamaño del paso $\mathbf{p}_k = \mathbf{p}_k^B$
 - En otro caso se puede usar el paso de Cauchy $\mathbf{p}_k = \mathbf{p}_k^C$.
- Se puede hacer algo más?

Mejorando el Punto de Cauchy

Observaciones

- Una estrategia simple es calcular el paso completo $\mathbf{p}_k^B = -\mathbf{B}_k^{-1} \nabla f_k$ siempre que \mathbf{B}_k sea definida positiva
 - Si se cumple la restricción $\|\mathbf{p}_k^B\| \leq \Delta_k$, entonces el tamaño del paso $\mathbf{p}_k = \mathbf{p}_k^B$
 - En otro caso se puede usar el paso de Cauchy $\mathbf{p}_k = \mathbf{p}_k^C$.
- Se puede hacer algo más?

Mejorando el Punto de Cauchy

Observaciones

- Una estrategia simple es calcular el paso completo $\mathbf{p}_k^B = -\mathbf{B}_k^{-1} \nabla f_k$ siempre que \mathbf{B}_k sea definida positiva
 - Si se cumple la restricción $\|\mathbf{p}_k^B\| \leq \Delta_k$, entonces el tamaño del paso $\mathbf{p}_k = \mathbf{p}_k^B$
 - En otro caso se puede usar el paso de Cauchy $\mathbf{p}_k = \mathbf{p}_k^C$.
- Se puede hacer algo más? El Método Dogleg!


Método Dogleg

Idea del Algoritmo

- Se puede usar siempre y cuando la **matriz B_k sea positiva definida**, **en otro caso usar el paso de Cauchy**


Trayectoria óptima $p(\Delta)$

Cual es el paso óptimo al variar la región de confianza? Si tomamos $\Delta \in [0, \|p_k^B\|]$ la trayectoria óptima $p(\Delta)$ sería



Trayectoria DogLeg

Aproximación de la trayectoria óptima usando el camino Dogleg



Método Dogleg

Idea del Algoritmo

- Minimizar el model cuadrático sin restricciones a lo largo del gradiente: $p_k^U = \alpha \nabla f_k$
- Minimizar el model cuadrático sin restricciones si B_k es positiva definida: $p_k^B = -B_k^{-1} \nabla f_k$, i.e, obtener el paso completo
- Calcular el tamaño de paso $p_k = F(p_k^U, p_k^B)$, i.e., el tamaño de paso es una función que depende del *paso completo* y de la *dirección de máximo descenso*.

Método Dogleg

Trayectoria Dogleg

- La primera línea del Dogleg va desde el origen hasta p_k^U
- La segunda línea va desde p_k^U hasta p_k^B , es decir, el Dogleg, $\tilde{p}(\tau)$, sigue la siguiente trayectoria

$$\tilde{p}(\tau) = \begin{cases} \tau p_k^U, & \text{si } 0 \leq \tau \leq 1 \\ p_k^U + (\tau - 1)(p_k^B - p_k^U), & \text{si } 1 \leq \tau \leq 2 \end{cases}$$

Método Dogleg

Minimizar el model cuadrático a lo largo del gradiente: p_k^U

- Si $p_k^U = \alpha \nabla f_k$, hallar el tamaño de paso α del problema sin restricciones (Unconstraint)

$$\begin{aligned}\alpha^* &= \arg \min_{\alpha} m_k(\alpha \nabla f_k) \\ m_k(\alpha \nabla f_k) &= f_k + \alpha \nabla f_k^T \nabla f_k + \frac{1}{2} \alpha^2 \nabla f_k^T \mathbf{B}_k \nabla f_k\end{aligned}$$

$$\alpha^* = -\frac{\nabla^T f_k \nabla f_k}{\nabla f_k^T \mathbf{B}_k \nabla f_k}$$

- Luego $p_k^U = -\frac{\nabla^T f_k \nabla f_k}{\nabla f_k^T \mathbf{B}_k \nabla f_k} \nabla f_k$

Método Dogleg

Minimizar el model cuadrático a lo largo del gradiente: \mathbf{p}_k^U

- Si $\mathbf{p}_k^U = \alpha \nabla f_k$, hallar el tamaño de paso α del problema sin restricciones (Unconstraint)

$$\begin{aligned}\alpha^* &= \arg \min_{\alpha} m_k(\alpha \nabla f_k) \\ m_k(\alpha \nabla f_k) &= f_k + \alpha \nabla f_k^T \nabla f_k + \frac{1}{2} \alpha^2 \nabla f_k^T \mathbf{B}_k \nabla f_k\end{aligned}$$

$$\alpha^* = -\frac{\nabla^T f_k \nabla f_k}{\nabla f_k^T \mathbf{B}_k \nabla f_k}$$

- Luego $\mathbf{p}_k^U = -\frac{\nabla^T f_k \nabla f_k}{\nabla f_k^T \mathbf{B}_k \nabla f_k} \nabla f_k$

Método Dogleg

WW

Luego

- $\mathbf{p}_k^U = -\frac{\nabla^T f_k \nabla f_k}{\nabla f_k^T \mathbf{B}_k \nabla f_k} \nabla f_k$ y $\mathbf{p}_k^B = -\mathbf{B}_k^{-1} \nabla f_k$
- El problema consiste en encontrar el **paso óptimo** que minimiza el problema cuadrático con restricciones en la trayectoria Dogleg, es decir, en

$$\tilde{\mathbf{p}}(\tau) = \begin{cases} \tau \mathbf{p}_k^U, & \text{si } 0 \leq \tau \leq 1 \\ \mathbf{p}_k^U + (\tau - 1)(\mathbf{p}_k^B - \mathbf{p}_k^U), & \text{si } 1 \leq \tau \leq 2 \end{cases}$$

- Como \mathbf{p}_k^U y \mathbf{p}_k^B son conocidos, entonces lo que tenemos que hallar es τ^* .

Método Dogleg

Lema

Si B es positiva definida entonces:

- $\|\tilde{p}(\tau)\|$ es una función creciente de τ y
- $m(\tilde{p}(\tau))$ es una función decreciente de τ .

Método Dogleg

[i] El caso $\tau \in [0, 1]$, entonces $\tilde{\mathbf{p}}(\tau) = \tau \mathbf{p}_k^U$, es trivial que $h(\tau) = \frac{1}{2} \|\tilde{\mathbf{p}}(\tau)\|^2$ es creciente

Método Dogleg

[i] Consideremos el caso $\tau \in [1, 2]$, cambiando variable $t = \tau - 1$, entonces $\tilde{\mathbf{p}}(t) = \mathbf{p}_k^U + t(\mathbf{p}_k^B - \mathbf{p}_k^U)$ con $t \in [0, 1]$

$$\begin{aligned}
 h(t) &= \frac{1}{2} \|\tilde{\mathbf{p}}(t)\|^2 &= \frac{1}{2} \|\mathbf{p}_k^U\|^2 + t(\mathbf{p}_k^U)^T(\mathbf{p}_k^B - \mathbf{p}_k^U) + \frac{1}{2} t^2 \|\mathbf{p}_k^B - \mathbf{p}_k^U\|^2 \\
 h'(t) &= (\mathbf{p}_k^U)^T(\mathbf{p}_k^B - \mathbf{p}_k^U) + t \|\mathbf{p}_k^B - \mathbf{p}_k^U\|^2 \\
 &\geq (\mathbf{p}_k^U)^T(\mathbf{p}_k^B - \mathbf{p}_k^U) \\
 &= -\frac{\mathbf{g}_k^T \mathbf{g}_k}{\mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k} \mathbf{g}_k^T (-\mathbf{B}_k^{-1} \mathbf{g}_k + \frac{\mathbf{g}_k^T \mathbf{g}_k}{\mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k} \mathbf{g}_k) \\
 &= \frac{\mathbf{g}_k^T \mathbf{g}_k}{(\mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k)^2} (\mathbf{g}_k^T \mathbf{B}_k^{-1} \mathbf{g}_k \mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k - (\mathbf{g}_k^T \mathbf{g}_k)^2) \geq 0
 \end{aligned}$$

pues $\mathbf{g}_k^T \mathbf{B}_k^{-1} \mathbf{g}_k \mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k \geq (\mathbf{g}_k^T \mathbf{g}_k)^2$, por Cauchy-Schwarz, luego $h'(t) \geq 0$ y por tanto $h(t)$ es creciente

Método Dogleg

[ii] Consideremos el caso $\tau \in [0, 1]$, entonces $\tilde{\mathbf{p}}(\tau) = \tau \mathbf{p}_k^U$

$$\begin{aligned}
 m(\tilde{\mathbf{p}}(\tau)) &= f_k + \mathbf{g}_k^T \tilde{\mathbf{p}}(\tau) + \frac{1}{2} \tilde{\mathbf{p}}(\tau)^T \mathbf{B}_k \tilde{\mathbf{p}}(\tau) \\
 m'(\tilde{\mathbf{p}}(\tau)) &= (\tilde{\mathbf{p}}'(\tau))^T \mathbf{g}_k + (\tilde{\mathbf{p}}'(\tau))^T \mathbf{B}_k \tilde{\mathbf{p}}(\tau) \\
 &= (\mathbf{p}_k^U)^T \mathbf{g}_k + \tau (\mathbf{p}_k^U)^T \mathbf{B}_k \mathbf{p}_k^U \\
 &\leq (\mathbf{p}_k^U)^T \mathbf{g}_k + (\mathbf{p}_k^U)^T \mathbf{B}_k \mathbf{p}_k^U, \text{ tomando } \tau = 1 \\
 &\leq \frac{\mathbf{g}_k^T \mathbf{g}_k}{\mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k} \left[-\mathbf{g}_k^T \mathbf{g}_k + \frac{\mathbf{g}_k^T \mathbf{g}_k}{\mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k} \mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k \right] = 0
 \end{aligned}$$

luego $m'(\tilde{\mathbf{p}}(t)) \leq 0$ y por tanto $m(\tilde{\mathbf{p}}(t))$ es decreciente

Método Dogleg

[ii] Consideremos el caso $\tau \in [1, 2]$, cambiando variable $t = \tau - 1$, entonces $\tilde{\mathbf{p}}(t) = \mathbf{p}_k^U + t(\mathbf{p}_k^B - \mathbf{p}_k^U)$ con $t \in [0, 1]$

$$\begin{aligned}
 m(\tilde{\mathbf{p}}(t)) &= f_k + \mathbf{g}_k^T \tilde{\mathbf{p}}(t) + \frac{1}{2} \tilde{\mathbf{p}}(t)^T \mathbf{B}_k \tilde{\mathbf{p}}(t) \\
 m'(\tilde{\mathbf{p}}(t)) &= (\tilde{\mathbf{p}}'(t))^T \mathbf{g}_k + (\tilde{\mathbf{p}}'(t))^T \mathbf{B}_k \tilde{\mathbf{p}}(t) \\
 &= (\mathbf{p}_k^B - \mathbf{p}_k^U)^T [\mathbf{g}_k + \mathbf{B}_k \mathbf{p}_k^U + t \mathbf{B}_k (\mathbf{p}_k^B - \mathbf{p}_k^U)] \\
 &= (\mathbf{p}_k^B - \mathbf{p}_k^U)^T (\mathbf{g}_k + \mathbf{B}_k \mathbf{p}_k^U) + t (\mathbf{p}_k^B - \mathbf{p}_k^U)^T \mathbf{B}_k (\mathbf{p}_k^B - \mathbf{p}_k^U) \\
 &\leq (\mathbf{p}_k^B - \mathbf{p}_k^U)^T (\mathbf{g}_k + \mathbf{B}_k \mathbf{p}_k^U) + (\mathbf{p}_k^B - \mathbf{p}_k^U)^T \mathbf{B}_k (\mathbf{p}_k^B - \mathbf{p}_k^U) \\
 &= (\mathbf{p}_k^B - \mathbf{p}_k^U)^T [\mathbf{g}_k + \mathbf{B}_k \mathbf{p}_k^U + \mathbf{B}_k (\mathbf{p}_k^B - \mathbf{p}_k^U)] \\
 &= (\mathbf{p}_k^B - \mathbf{p}_k^U)^T [\mathbf{g}_k + \mathbf{B}_k \mathbf{p}_k^B] = 0
 \end{aligned}$$

pues $\mathbf{g}_k + \mathbf{B}_k \mathbf{p}_k^B = 0$ luego $m'(\tilde{\mathbf{p}}(t)) \leq 0$ y por tanto $m(\tilde{\mathbf{p}}(t))$ es decreciente

Método Dogleg

Observaciones

Basados en el Lema anterior se tiene lo siguiente

- La trayectoria $\tilde{p}(\tau)$ intercepta a la *región de confianza*, $\|p\| = \Delta_k$, en un sólo punto si $\|p_k^B\| \geq \Delta_k$.
- Si $\|p_k^B\| \leq \Delta_k$ entonces el tamaño de paso óptimo es $p_k = p_k^B$, puesto que $m(\tilde{p}(\tau))$ decrece a lo largo del camino Dogleg.

Método Dogleg

Observaciones

- En otro caso, ie, si $\|p_k^B\| > \Delta_k$, hay que hallar el intercepto entre la trayectoria Dogleg y la region de confianza,
 - Si $\|p_k^U\| \geq \Delta_k$ entonces $p_k = p_k^C$
 - De lo contrario (ie, $\|p_k^U\| < \Delta_k$), se tiene que resolver la siguiente ecuación para τ

$$\|p_k^U + (\tau - 1)(p_k^B - p_k^U)\|^2 = \Delta^2$$

Método Dogleg

A partir de

$$\|\mathbf{p}_k^U + (\tau - 1)(\mathbf{p}_k^B - \mathbf{p}_k^U)\|^2 = \Delta^2$$

Tenemos que resolver la ecuación cuadrática

$$a\lambda^2 + b\lambda + c = 0$$

donde $\tau = \lambda + 1$ y


$$a = \|\mathbf{p}_k^B - \mathbf{p}_k^U\|^2, \quad b = 2(\mathbf{p}_k^B)^T(\mathbf{p}_k^B - \mathbf{p}_k^U), \quad c = \|\mathbf{p}_k^U\|^2 - \Delta^2$$

Finalmente

$$\mathbf{p}_k = \mathbf{p}(\tau^*) = \begin{cases} \tau^* \mathbf{p}_k^U, & \text{si } 0 \leq \tau^* \leq 1 \\ \mathbf{p}_k^U + (\tau^* - 1)(\mathbf{p}_k^B - \mathbf{p}_k^U), & \text{si } 1 \leq \tau^* \leq 2 \end{cases}$$

Caso 1: DogLeg


Si p_k^B está en el interior de la región de confianza



$$\|p_k^B\| \leq \Delta_k \text{ , i.e. } \|p_k^U\| \leq \Delta_k \text{ y } p_k^C = p_k^U$$

Caso 2: DogLeg

Si p_k^B está fuera de la región de confianza y $1 \leq \tau^* \leq 2$



$$\|p_k^U\| \leq \Delta_k \implies p_k^C = p_k^U$$

$$\|p_k^B\| > \Delta_k$$

Trust region-Dogleg

- 1: Given $\hat{\Delta} > 0$, $\Delta_0 \in (0, \hat{\Delta})$ y $\eta \in [0, \frac{1}{4})$
- 2: **for** $k = 0, 1, 2, \dots$ **do**
- 3: Compute \mathbf{p}_k using Dogleg
- 4: Compute $\rho_k = \frac{f(\mathbf{x}_k) - f(\mathbf{x}_k + \mathbf{p}_k)}{m_k(0) - m_k(\mathbf{p}_k)}$
- 5: **if** $\rho_k > \eta$ **then**
- 6: $\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{p}_k$
- 7: **else**
- 8: $\mathbf{x}_{k+1} = \mathbf{x}_k$
- 9: **end if**
- 10: Compute Δ_{k+1} using $(\rho_k, \mathbf{p}_k, \Delta_k, \rho_k, \hat{\Delta})$.
- 11: **end for**